مشروع التخرج · مسار تعلّم الآلة وتحليل البيانات · NTI

BusinessLaunch AI

هل أفتح مطعماً أو مقهى في هذا المكان؟

الدليل الشامل لشرح المشروع والموقع: البيانات، والنماذج، والنتائج، وطريقة استخدام التطبيق – مدعوماً بالرسوم البيانية ولقطات الشاشة.

الانحدار Regression · معالجة اللغة NLP · التجميع Clustering · مونت كارلو Monte Carlo · تطبيق Streamlit

سيف
ذكاء الموقع ونموذج الانحدار

مريم
معالجة اللغة وتحليل المشاعر

بلال
التجميع والتمويل وتكامل التطبيق

بيانات Yelp المفتوحة · مدينة فيلادلفيا (الولايات المتحدة) · أكتوبر 2026 ·
github.com/BelalOsaKa/BusinessLaunchAI

المحتويات

ما الذي ستجده في هذا الدليل؟

1. الفكرة والمشكلة التي يحلّها المشروع
2. البيانات المستخدمة ومراحل تنظيفها
3. كيف تعمل أجزاء النظام معاً (البنية العامة)
4. الجزء الأول – سيف: المنافسة والشعبية (نموذج الانحدار)
5. الجزء الثاني – مريم: آراء العملاء (معالجة اللغة الطبيعية)
6. الجزء الثالث – بلال: أنواع الأسواق، والمحاكاة المالية، والتوصية النهائية
7. شرح الموقع صفحةً صفحة، مع لقطات الشاشة
8. الألعاب التفاعلية «تحدَّ الذكاء الاصطناعي»
9. جودة الكود والاختبارات والنشر على الإنترنت
10. التحديات والحلول، والقيود، والعمل المستقبلي
11. الخلاصة، ومسرد المصطلحات (عربي - إنجليزي)

المشروع في سطور

صاحب المشروع يختار نقطة على خريطة فيلادلفيا، فيعرض له التطبيق خمس إجابات: **كم عدد المنافسين وما مدى الشعبية المتوقعة**، و**ماذا يقول العملاء في المنطقة**، و**ما نوع السوق**، و**هل الأرقام المالية مجدية وما درجة المخاطرة**، ثم **توصية نهائية مفسَّرة**: واعد، أو تقدّم بحذر، أو مخاطرة عالية.

6,174	**703,584**	**1.29M**	**7 + 3**
مطعماً ومقهى تم تحليلها	مراجعة عملاء بعد التنظيف	تسجيل زيارة (check-ins)	صفحات في الموقع + ألعاب تفاعلية

1 · الفكرة والمشكلة

لماذا هذا المشروع؟

افتتاح مطعم من أكثر المشاريع الصغيرة خطورة. في بياناتنا نفسها، **39% من مطاعم ومقاهي فيلادلفيا أغلقت بالفعل** حتى يناير 2022. وأشهر أسباب الفشل – الموقع الخاطئ، والمنافسة الأكبر من المتوقع، وسوء فهم ما يريده العملاء، والتكاليف غير الواقعية – يمكن قراءتها من البيانات العامة **قبل** توقيع عقد الإيجار.

السؤال الذي يجيب عنه المشروع

«إذا أراد رجل أعمال افتتاح مطعم أو مقهى في هذا الموقع، فما الفرص، وما المنافسة، وما توقعات العملاء، وما المخاطر المالية التي قد يواجهها؟»

الحل: نقطة واحدة على الخريطة ← خمس إجابات



لمن هذا التطبيق؟

- **رواد الأعمال** الذين يدرسون افتتاح مطعم أو مقهى ويريدون قراراً مبنياً على البيانات.
- **المستثمرون والبنوك** الذين يحتاجون تقريراً واضحاً قابلاً للتنزيل يشرح الفرص والمخاطر.
- **الطلاب والمهتمون بتعلّم الآلة**: الألعاب والتوضيحات تشرح كيف «تفكّر» النماذج.

ملاحظة مهمة: بيانات Yelp لا تحتوي على الإيرادات أو التكاليف، لذلك نقيس «الشعبية» بعدد المراجعات، وجميع الأرقام المالية مبنية على افتراضات المستخدم نفسه – ونوضّح ذلك دائماً داخل التطبيق.

2 · البيانات

من 7 ملايين سطر إلى مدينة واحدة

استخدمنا ثلاثة ملفات من Yelp Open Dataset (منشورة على Kaggle). ركّزنا على مدينة **فيلادلفيا، ولاية بنسلفانيا** فقط، لأنها مدينة كبيرة فيها بيانات كافية.

الملف	البيانات الأصلية	بعد الاختيار والتنظيف	فيمَ استخدمناه
🏪 الأنشطة التجارية business.json	150,346	14,570 → 6,174	الموقع، التقييم، السعر، الخصائص، ساعات العمل
💬 المراجعات review.json (5 GB)	6,990,280	704,625 → 703,584	تحليل المشاعر وموضوعات الشكاوى
📍 تسجيلات الزيارة checkin.json	131,930	تسجيلاً 1,287,190	عمر النشاط ومستوى الحركة في المنطقة

الـ **6,174** نشاطاً هي: **5,855 مطعماً** + **319 مقهى** (تصنيف Cafes أو Coffee & Tea). المراجعات تمتد من 2005 حتى يناير 2022.

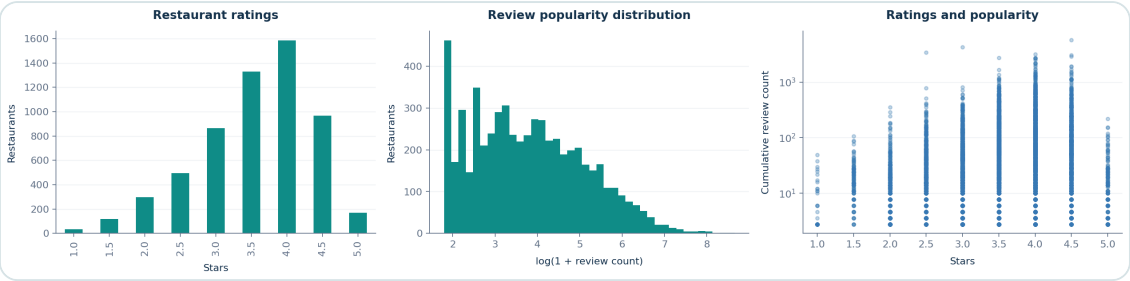
مراحل المعالجة المسبقة (التنظيف)

سيف الأنشطة وتسجيلات الزيارة

- توحيد اسم المدينة والولاية (Philadelphia, PA).
- حذف المعرّفات المكررة أو الفارغة، وتسجيل 5 صفوف بإحداثيات مستحيلة في ملف للمراجعة بدل حذفها بصمت.
- تحويل الخصائص النصية إلى أرقام، مثل `u'full_bar'` ← 2 و `'True'` ← 1.
- تحويل ساعات العمل إلى: أيام العمل، وعدد الساعات أسبوعياً، والأيام المتأخرة ليلاً.
- استخراج «عمر النشاط على Yelp» من أول تسجيل زيارة.
- تعويض القيم الناقصة باستخدام بيانات التدريب فقط (لتجنّب التسريب).

مريم المراجعات

- قراءة ملف الـ 5 GB على دفعات (100 ألف سطر في كل مرة) والاحتفاظ بمراجعات أنشطتنا فقط.
- حذف 975 مراجعة مكررة و66 نصاً فارغاً.
- تحويل الحروف إلى صغيرة وحذف الروابط وعلامات الترقيم.
- **الحفاظ على النفي:** don't ← do not، حتى يبقى «not good» معناه سلبياً.
- حذف الكلمات الشائعة (stopwords) فقط للرسوم والموضوعات، وليس للمصنّف.
- التصنيف من النجوم: 1-2 ★ سلبي، 4-5 ★ إيجابي.

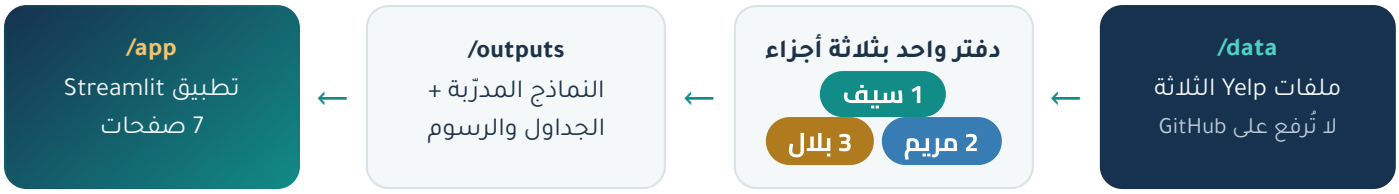


توزيع التقييمات، والتوزيع اللوغاريتمي لعدد المراجعات، والعلاقة بين التقييم والشعبية.

3 · البنية العامة

كيف تعمل أجزاء النظام معاً؟

الفكرة الأساسية: **ندرّب النماذج مرة واحدة** في دفتر Jupyter، ونحفظها، ثم **يقرأها التطبيق فقط** دون إعادة تدريب، لذلك يفتح خلال ثوانٍ ولا يحتاج ملف الـ 5 GB.



الحزمة المشتركة src/businesslaunch/

كل الدوال المهمة (حساب المنافسين، تحليل المراجعات، خصائص الأحياء، المحاكاة المالية، التوصية) مكتوبة مرة واحدة في هذه الحزمة، ويستخدمها **الدفتر والتطبيق معاً**. النتيجة: الرقم الذي تراه في الموقع هو نفسه الرقم الذي قيّمناه في الدفتر.

هيكل المستودع على GitHub

المجلد / الملف	المحتوى
notebooks/BusinessLaunchAI_ML_Pipeline.ipynb	دفتر تعلّم الآلة الكامل بأجزائه الثلاثة
src/businesslaunch/	الكود المشترك المختبَر (data, location, competitor_analysis, aspects, market, finance, recommend)
app/	التطبيق: ملف الدخول Home.py، والتصميم ui.py، و7 صفحات في views/
outputs/member1, member2, member3	النماذج المدرّبة والمقاييس والرسوم والجداول
tests/	اختبارات الوحدات واختبارات صفحات التطبيق
docs/ · README.md · requirements.txt	التوثيق، وشرح التشغيل، والمكتبات بإصداراتها الدقيقة

مفتاح الربط بين الأجزاء

كل الجداول ترتبط بمعرّف النشاط `business_id`: قائمة مريم (6,174 مطعماً ومقهى) هي «عالم المنافسة»، ومطاعم سيف (5,855) جزء منها.

الجزء الأول · سيف

المنافسة والشعبية: نموذج الانحدار

ما مدى ازدحام المكان بالمنافسين، وكم قد تبلغ شعبية مطعم جديد فيه؟

ماذا نتنبأ؟

الهدف هو **عدد مراجعات Yelp** للمطعم، وهو مقياس للشعبية وليس للإيرادات. الوسيط 39 مراجعة بينما المتوسط 114، أي أن قلة من المطاعم الشهيرة لديها آلاف المراجعات؛ لذلك نتنبأ بلوغاريتم القيمة `log(1 + reviews)` ثم نعيدها.

الخصائص (57 خاصية)

📍 المنافسة والموقع

عدد المطاعم في نطاق 0.5 و1 و2 كم (بمسافة haversine الحقيقية على سطح الأرض باستخدام BallTree)، والمفتوح منها، والكثافة، والبعد عن مبنى البلدية.

⏳ النشاط والعمر

عدد السنوات منذ أول تسجيل زيارة، ومتوسط حركة الزيارات لدى الجيران.

🏷️ ملف المطعم

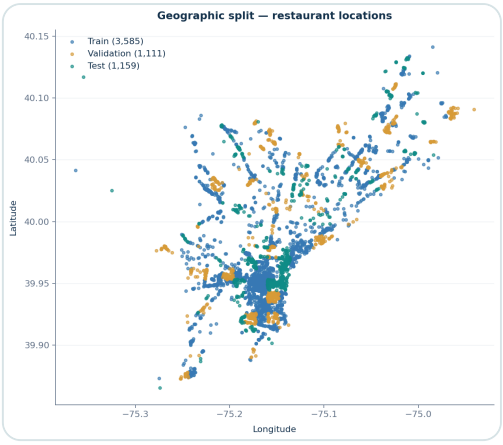
التقييم، والسعر، و13 خدمة (طلب خارجي، توصيل، حجز…)، والكحول، والضوضاء، والواي فاي، والمواقف.

🕒 الساعات والنوع

ساعات العمل أسبوعياً، وأيام العمل، و20 تصنيفاً للمطبخ مختارة من بيانات التدريب فقط.

🔒 لماذا تقسيم «مكاني»؟

لو قسّمنا البيانات عشوائياً، لتعلّم النموذج من الجيران المتشابهين وبدت نتائجه أفضل من الحقيقة. لذلك قسّمنا المدينة إلى مربعات بحجم ~1 كم، وكل مربع يذهب كاملاً إلى التدريب (3,585) أو التحقق (1,111) أو الاختبار (1,159). وأضفنا **8 فحوصات آلية ضد التسريب** نجحت كلها، مثل: تغيير كل أعداد المراجعات لا يغيّر الخصائص.



خريطة التقسيم المكاني: الأزرق تدريب، والأصفر تحقق، والأخضر اختبار.

النماذج والنتائج

جرّبنا الأنواع الأربعة المطلوبة مع نموذج أساسي بسيط (الوسيط). كل النماذج تمر بنفس الخطوات: تعويض القيم الناقصة، والتوحيد القياسي، والهدف اللوغاريتمي. اختير النموذج **حسب خطأ التحقق**، ثم قِسنا الاختبار مرة واحدة.

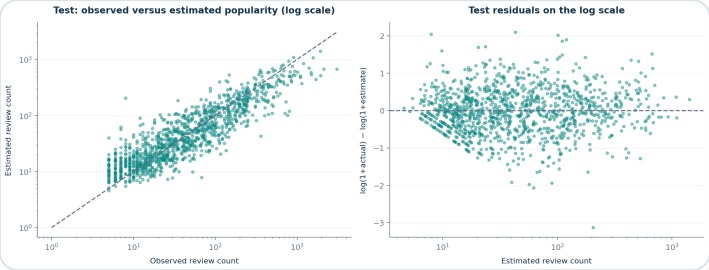
النموذج	تحقق MAE	اختبار MAE	اختبار RMSE	اختبار R^2
النموذج الأساسي (الوسيط)	65.5	99.4	239.6	−0.10
الانحدار الخطي Linear Regression	41.6	59.4	157.9	0.52
الغابة العشوائية Random Forest	39.9	57.5	160.1	0.51
التعزيز التدرجي Gradient Boosting	42.3	62.7	175.9	0.41
✓ **HistGradientBoosting (المختار)**	**37.4**	**51.3**	**142.7**	**0.61**

أهم درس: هندسة الخصائص تغلّبت على اختيار النموذج

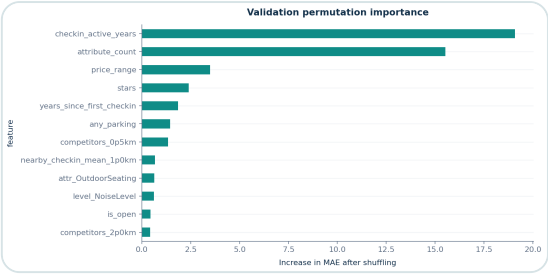
0.06
R^2 باستخدام الموقع والمنافسة فقط

0.61
R^2 بعد إضافة العمر والخصائص والساعات والحركة

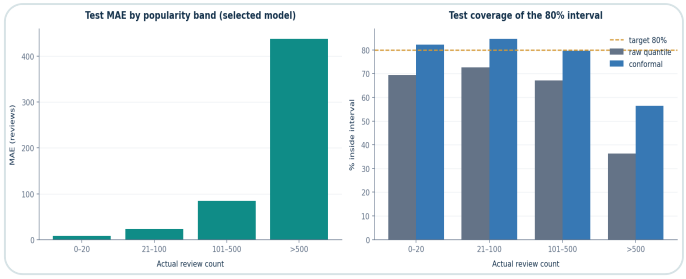
−48%
انخفاض الخطأ مقارنة بالنموذج الأساسي



القيم الحقيقية مقابل التقديرات على مقياس لوغاريتمي لمطاعم الاختبار: النقاط تتبع القطر.



أهم الخصائص: عمر النشاط واكتمال صفحة Yelp ثم السعر والتقييم.



نطاق الثقة 80% بعد المعايرة يغطي 81.4% من مطاعم الاختبار (كان 68.6%).

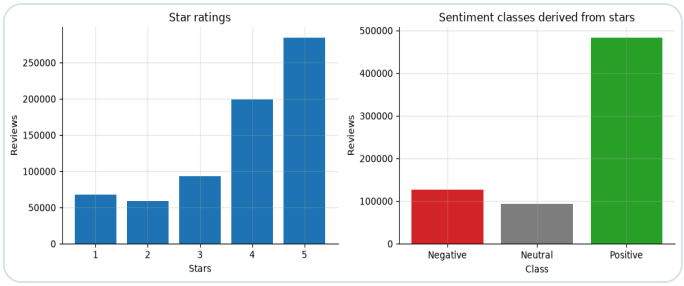
اختبارات الصلابة

- **بحث عشوائي في 20 إعداداً** للمعاملات: لم يتفوق على النموذج الحالي (38.2 مقابل 37.4)، أي أن الاختيار صحيح.
- **دالة خسارة بواسون** المناسبة للأعداد: أسوأ (40.1)، فاحتفظنا بالهدف اللوغاريتمي.
- **نطاق متوقع بدل رقم واحد:** نموذجان للمئين 10 و90 مع معايرة conformal على بيانات التحقق، ويظهر هذا النطاق في التطبيق.
- **نقطة الضعف:** المطاعم الشهيرة جداً (أكثر من 500 مراجعة) ما زالت تُقدَّر بأقل من حقيقتها.

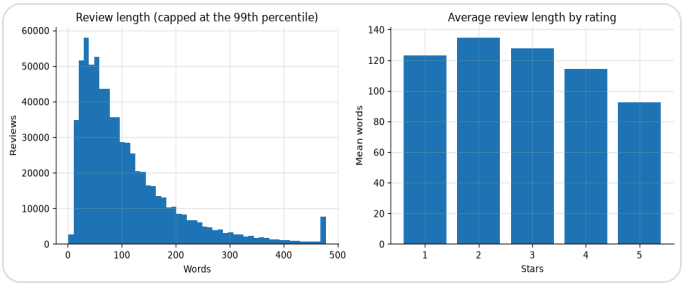
الجزء الثاني · مريم

آراء العملاء: معالجة اللغة الطبيعية

ماذا يحب عملاء المنافسين القريبين، وما الذي يدفعهم لكتابة مراجعات سيئة؟



68.7% من المراجعات إيجابية (4-5 ★) و18% سلبية؛ بيانات غير متوازنة.



غير الراضين يكتبون أكثر: 135 كلمة في مراجعات 2★ مقابل 93 في 5★.

خطوات النموذج

1. **تحويل النص إلى أرقام بـ TF-IDF:** كل مراجعة تصبح متجهاً من الكلمات وأزواج الكلمات (مثل «not good») بوزن أعلى للكلمات المميزة مثل rude وdelicious.
2. **التسميات من النجوم:** 1-2 ★ = سلبي، 4-5 ★ = إيجابي، واستُبعدت مراجعات 3★ المختلطة من التدريب فقط.
3. **عينة من 100 ألف مراجعة** بنفس نسبة السلبي في الكل (20.7%).
4. **التقسيم حسب المطعم وليس حسب المراجعة:** حتى لا يحفظ النموذج أسماء الأطباق والموظفين لمطعم معين. الاختبار يضم 1,128 مطعماً لم يرها النموذج.
5. **ضبط المعاملات بـ GridSearchCV** مع GroupKFold على بيانات التدريب فقط، وبمقياس macro F1 لأن الدقة وحدها تخفي ضعف الفئة الأصغر.

النموذج	الإعداد	تحقق F1	دقة تحقق
بايز الساذج Naive Bayes	α = 1.0	0.889	0.929
بايز الساذج بعد الضبط	α = 0.1	0.895	0.932
الانحدار اللوجستي Logistic Regression	C = 1	0.929	0.954
✓ الانحدار اللوجستي بعد الضبط	**C = 10**	**0.943**	**0.961**

0.944
macro F1 على الاختبار

96.4%
الدقة على الاختبار

0.890
اكتشاف الشكاوى (Recall)

79.6%
دقة التخمين الدائم «إيجابي»

الجزء الثاني · مريم

تحليل الأخطاء، وموضوعات الشكاوى، والجوانب

📊 لا يوجد إفراط في التعلّم

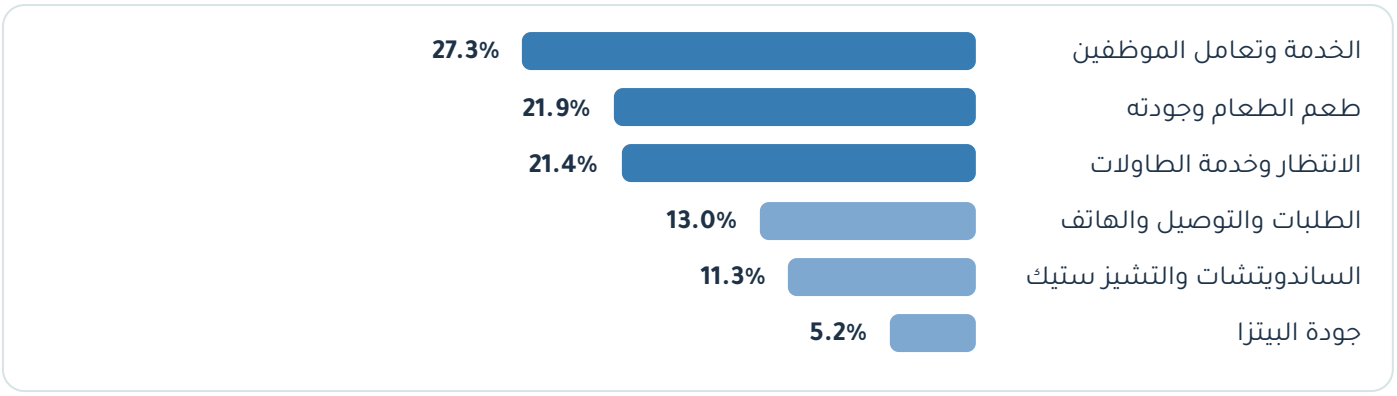
macro F1 = 0.989 تدريب، 0.943 تحقق، 0.944 اختبار. الفجوة صغيرة (0.047)، والتحقق ≈ الاختبار، أي أن النتيجة تعمم على مطاعم جديدة.

🔍 أين يخطئ النموذج؟

مراجعات 2★ هي الأصعب (17.3% خطأ) لأنها تخلط المدح بالشكوى: «الطعام جيد، **لكن** الخدمة سيئة». كلمتا but / however تظهران في 62% من الأخطاء مقابل 50% من الصحيح.

ستة موضوعات للشكاوى بنموذج NMF

طبّقنا تحليل المصفوفات غير السالبة (NMF) على 126,652 مراجعة سلبية لاكتشاف مجموعات الكلمات المتكررة. اخترنا 6 موضوعات لأنها أعطت أعلى «تنوع» للكلمات (0.88)، ثم سمّينا كل موضوع بعد قراءة كلماته وأمثلته:



في التطبيق نقارن نسبة كل موضوع حول الموقع المختار بنسبته في المدينة كلها. مثال: قرب مبنى البلدية، شكاوى الانتظار **28%** محلياً مقابل **21%** في المدينة – فرصة واضحة لمطعم جديد يتفوق في السرعة.

تحليل المشاعر حسب الجانب (Aspect sentiment)

التقييم الواحد يخفي آراء مختلطة، لذلك نقسم المراجعة إلى جمل، ونربط كل جملة بأحد 7 جوانب (الطعام، الخدمة، الانتظار، السعر، الأجواء، النظافة، التوصيل)، ثم نقيّم كل جملة بالنموذج المدرّب. مثال حقيقي:

"The food was absolutely delicious and the portions were huge. But we waited 45 minutes for a table and the waitress was rude."

الطعام: إيجابي	الانتظار: سلبي	الخدمة: سلبي
100%	1%	1%

تحسينات جاهزة ومختبرة (تحتاج ملف المراجعات الكامل لتشغيلها): ثلاثة أضعاف بيانات التدريب، ومفردات أوسع، ونموذج SVM معاير، وضبط عتبة القرار.

الجزء الثالث · بلال

أنواع الأسواق، والمال، والقرار

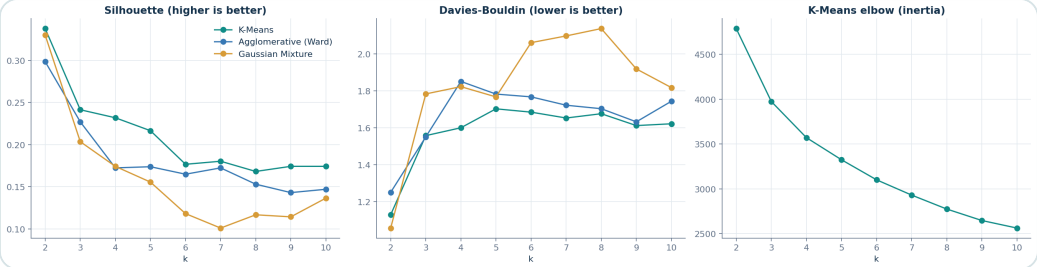
ما نوع السوق في هذا المكان، وهل الأرقام مجدية، وهل أفتح هنا؟

خصائص الأحياء: 611 منطقة × 13 خاصية

جمعنا نتائج سيف ومريم في جدول واحد لـ 6,174 نشاطاً، ثم قسّمنا فيلادلفيا إلى خلايا بحجم 0.5 كم، ولكل خلية لخّصنا كل ما يقع ضمن **1 كم**: العرض (عدد المنافسين)، والبقاء (نسبة المفتوح)، والطلب (الزيارات والمراجعات لكل نشاط)، والجودة (التقييم ونسبة 1-2★ من نتائج مريم)، ونوع الشكاوى، وتنوع المطابخ، ونسبة المقاهي والبارات، والسعر، وعمر الأنشطة. استبعدنا المناطق التي فيها أقل من 10 أنشطة، فبقيت 611 منطقة.

اختيار طريقة التجميع وعدد المجموعات

قارنّا ثلاث خوارزميات (K-Means وAgglomerative Ward وGaussian Mixture) لأعداد من 2 إلى 10، بمقاييس Silhouette وDavies-Bouldin وCalinski-Harabasz ومنحنى المرفق. وحددنا القاعدة **قبل** النظر في النتائج: 4 مجموعات على الأقل، وثبات ARI ≥ 0.8، ولا مجموعة أصغر من 5%، ثم أعلى Silhouette.



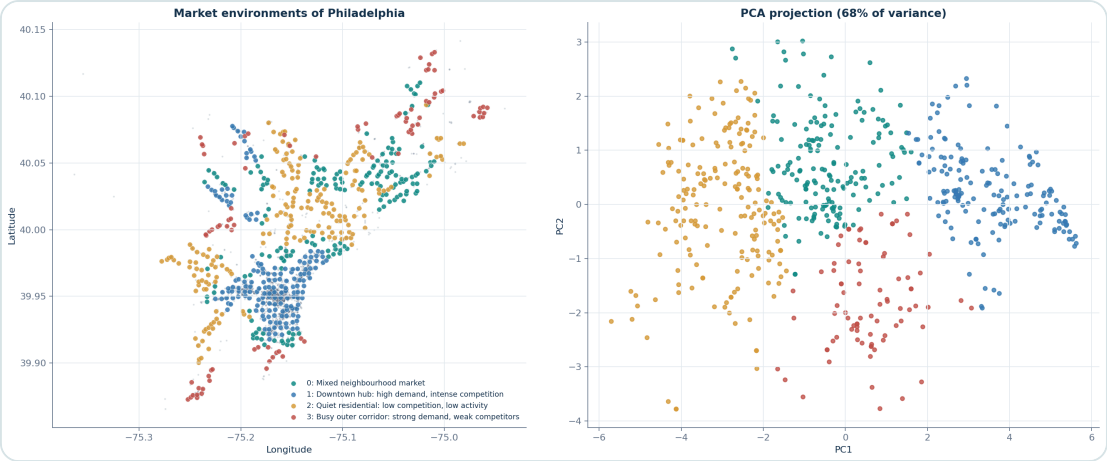
مقاييس الجودة للخوارزميات الثلاث حسب عدد المجموعات.

عند k = 4	Silhouette ↑	Davies-Bouldin ↓	Calinski-H ↑
K-Means ✓	**0.232**	**1.60**	**248**
Agglomerative (Ward)	0.172	1.85	218
Gaussian Mixture	0.174	1.82	203

فاز K-Means بالمقاييس الثلاثة، وهو ثابت (ARI = 0.87 على 30 عينة bootstrap)، ويستطيع تصنيف موقع جديد يختاره المستخدم – وهذا ما يحتاجه التطبيق. قيمة Silhouette 0.23 طبيعية للأحياء الحقيقية لأنها تتداخل تدريجياً.

الجزء الثالث · بلال

أربع بيئات سوقية في فيلادلفيا



خريطة البيئات السوقية وإسقاط PCA. الإحداثيات لم تكن من المدخلات، ومع ذلك أعاد التجميع اكتشاف جغرافيا المدينة.

مركز وسط المدينة

~210 منافساً ضمن 1 كم، وأعلى طلب، لكن 56% فقط ما زالت مفتوحة. مزدحم وعالي المخاطرة.

ممر خارجي نشط

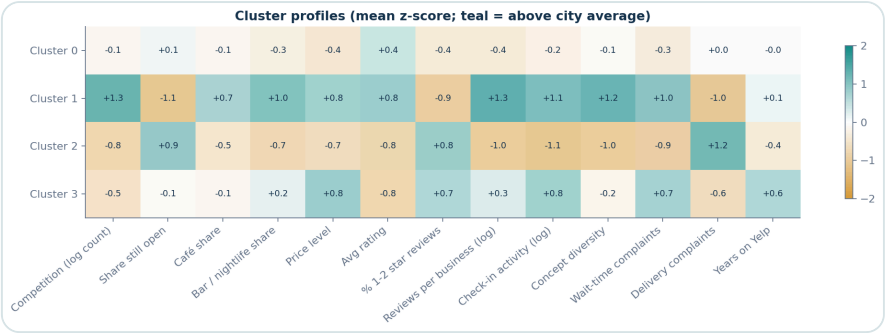
طلب قوي لكل نشاط مع منافسين ضعيفي التقييم (3.29★). أفضل توازن بين الفرصة والمخاطرة لمشغّل متميّز.

سوق حي مختلط

متوسط في كل شيء (تقييم 3.71★). النجاح يعتمد على ملاءمة ذوق الحي وبناء زبائن دائمين.

منطقة سكنية هادئة

منافسون قليلون وبقاء جيد (82% مفتوحة) لكن حركة منخفضة. يجب أن تصنع طلبك بنفسك (توصيل، وجهة مميزة).



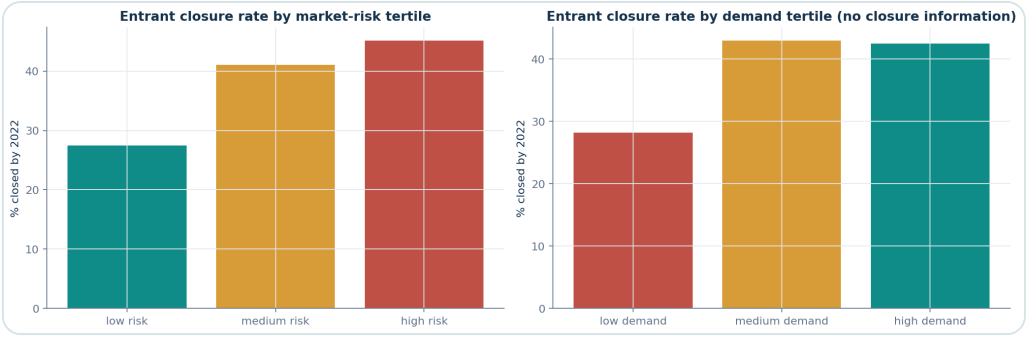
متوسط كل خاصية لكل مجموعة بالانحرافات المعيارية عن متوسط المدينة (الأخضر أعلى من المتوسط).

اختبار الحساسية: عند تغيير نصف القطر إلى 1.5 كم بقيت المجموعات متقاربة (ARI = 0.60)، بينما 0.5 كم صغير جداً (ARI = 0.30) – وهذا يدعم اختيار 1 كم.

الجزء الثالث · بلال

هل تتنبأ درجة المخاطرة بالإغلاق فعلاً؟

درجات الفرصة والمخاطرة قواعد شفافة، لذلك اختبرناها على نتيجة حقيقية لم تُبنَ عليها: **هل بقيت المطاعم والمقاهي التي افتُتحت بين 2012 و2019 مفتوحة؟** قيّمنا 2,803 نشاطاً جديداً بنفس طريقة تقييم أي موقع مقترح، مع استبعاد النشاط نفسه من حساب منطقته.



نسبة الإغلاق حسب شريحة المخاطرة (يمين) وحسب شريحة الطلب (يسار).

27% → 45%
نسبة الإغلاق في المناطق منخفضة مقابل عالية المخاطرة

AUC 0.60
قدرة درجة المخاطرة على التنبؤ بالإغلاق

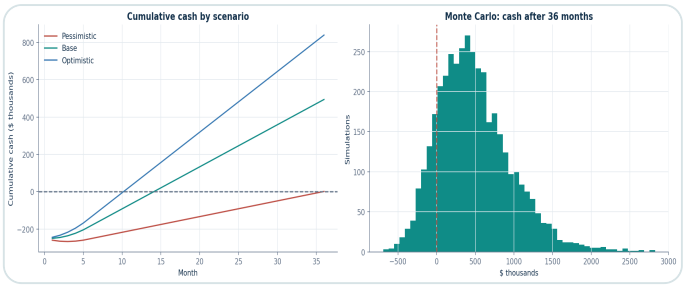
AUC 0.41
الطلب وحده: المناطق المزدحمة تُغلق أكثر!

💡 اكتشاف مهم: الازدحام لا يعني الأمان

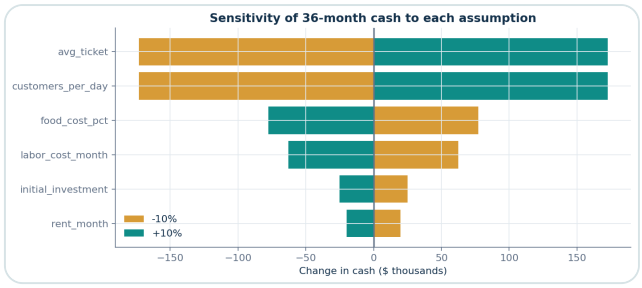
المناطق ذات الطلب العالي تجذب منافسين أكثر وتشهد تغيّراً أكبر في الأنشطة. لذلك لا تعتمد التوصية على الطلب وحده أبداً، بل توازن دائماً بين الفرصة والمخاطرة.

المحاكي المالي

بما أن Yelp لا يحتوي على بيانات مالية، فالمحاكي يعتمد على افتراضات المستخدم (الإيجار، الرواتب، عدد العملاء، متوسط الفاتورة، تكلفة الطعام...). البيانات تقترح القيم الافتراضية فقط: مستوى الأسعار المحلي يحدد الفاتورة، ومستوى الطلب يعدّل عدد العملاء بحد أقصى ±40%.



النقد التراكمي لثلاثة سيناريوهات، وتوزيع 4,000 محاكاة مونت كارلو.



أكثر الافتراضات تأثيراً: عدد العملاء ومتوسط الفاتورة.

نقطة التعادل اليومية = التكاليف الثابتة ÷ (الفاتورة × (1 − نسبة التكاليف المتغيرة)) ÷ أيام العمل. مثال: 120 عميلاً يومياً بفاتورة $28 ← نقطة التعادل 66 عميلاً يومياً، و75% من المحاكاة تسترد الاستثمار خلال 24 شهراً.

محرك التوصية: درجات مفسَّرة وقرار واحد

الفرصة
50% الطلب + 25% عدم رضا العملاء + 25% ضعف تقييم المنافسين

مخاطرة السوق
50% المنافسة + 50% نسبة الإغلاق

المخاطرة الكلية
60% مخاطرة السوق + 40% المخاطرة المالية

كل درجة هي **مئين** مقارنة بكل مناطق فيلادلفيا الـ 611: الدرجة 70 تعني أعلى من 70% من المناطق. ثم يصدر الحكم:

الحكم	الشرط
✅ **واعد**	الفرصة ≥ 55 والمخاطرة الكلية ≥ 50
⚠️ **تقدّم بحذر**	إشارات مختلطة: تحقق من الافتراضات أولاً
⛔ **مخاطرة عالية**	المخاطرة الكلية ≤ 70 أو احتمال خسارة دائمة > 50%

بعدها يكتب المحرك تلقائياً **نقاط القوة والمخاطر والإجراءات المقترحة** من الأرقام، ويقترح **أنواع مطابخ ناقصة** في المنطقة، و**مناطق أفضل** ضمن 3 كم.

أمثلة حقيقية من التطبيق

الموقع	البيئة السوقية	الفرصة	الحكم
وسط المدينة (مبنى البلدية)	مركز وسط المدينة	55	⚠️ تقدّم بحذر
إيست باسيونك	مركز وسط المدينة	55	⚠️ تقدّم بحذر
شمال شرق المدينة (فرانكفورد)	سوق حي مختلط	57	✅ واعد

وسط المدينة في سطر واحد

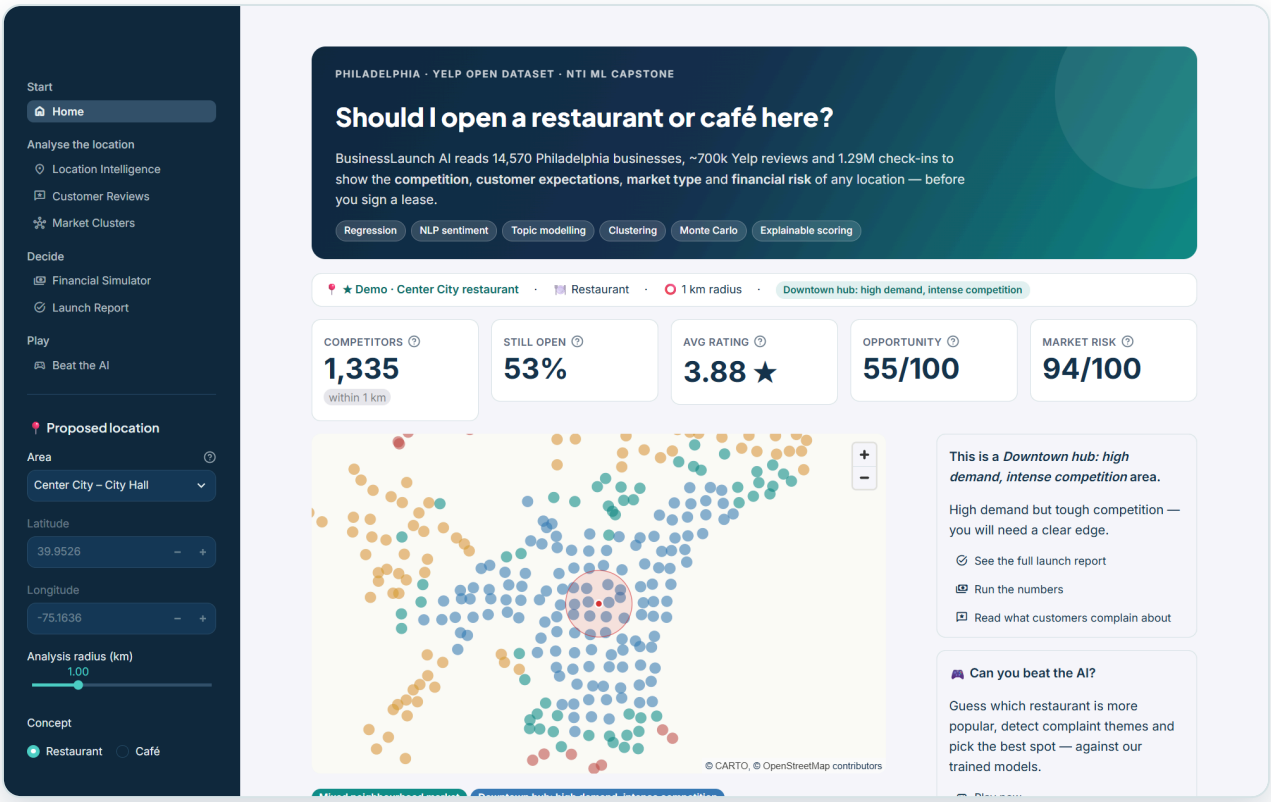
طلب 97/100، لكن 1,335 منافساً و53% فقط ما زالت مفتوحة، وشكاوى الانتظار 28% مقابل 21% في المدينة ← الحكم «تقدّم بحذر»، والإجراء المقترح: التفوق في سرعة الخدمة.

شرح الموقع

تطبيق BusinessLaunch AI صفحةً صفحة

سبع صفحات مقسّمة إلى: البداية · تحليل الموقع · اتخاذ القرار · اللعب

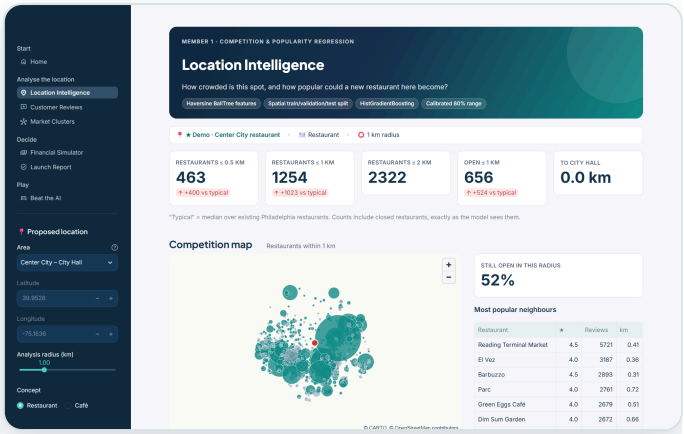
🏠 الصفحة الرئيسية



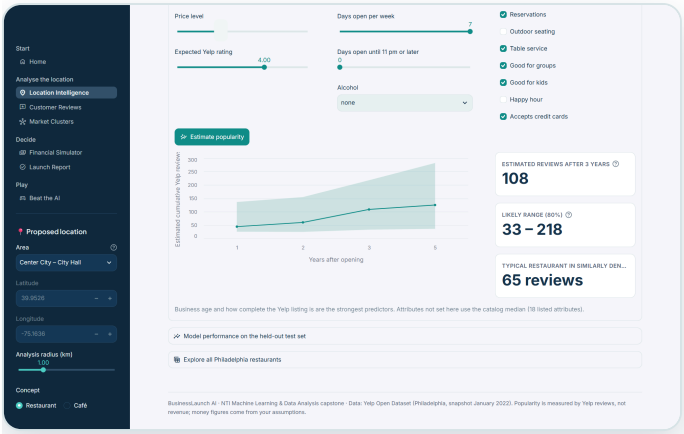
الصفحة الرئيسية: الشريط الجانبي لاختيار الموقع، وبطاقات الأرقام الأساسية، وخريطة البيئات السوقية.

1. **اختر الموقع من الشريط الجانبي:** منطقة جاهزة (وسط المدينة، فيشتاون، يونيفرسيتي سيتي…) أو أدخل أي إحداثيات، ثم حدد نصف قطر التحليل ونوع المشروع (مطعم أو مقهى).
2. **البطاقات العلوية:** عدد المنافسين، ونسبة المفتوح، ومتوسط التقييم، ودرجتا الفرصة والمخاطرة. لكل رقم شرح يظهر عند الوقوف على علامة (؟).
3. **الخريطة:** ملوّنة حسب البيئات السوقية الأربع، والنقطة الحمراء هي موقعك.
4. **حفظ الموقع** 💾 **:** احفظ الموقع باسم، ليظهر بنجمة ★ أعلى القائمة ويمكن مقارنته لاحقاً في التقرير.

ذكاء الموقع و آراء العملاء



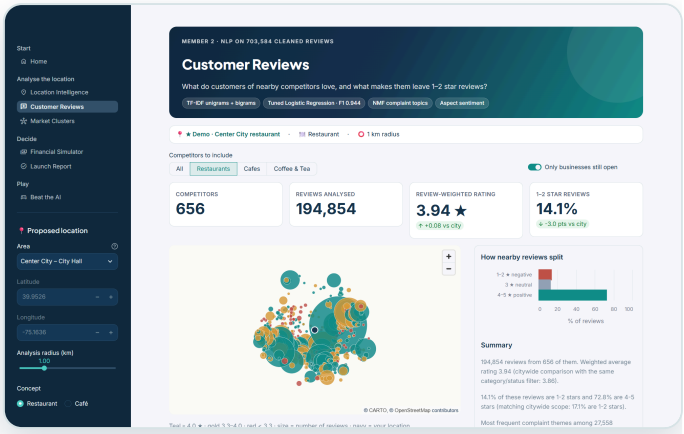
صفحة ذكاء الموقع: المنافسون حول النقطة وخريطتهم.



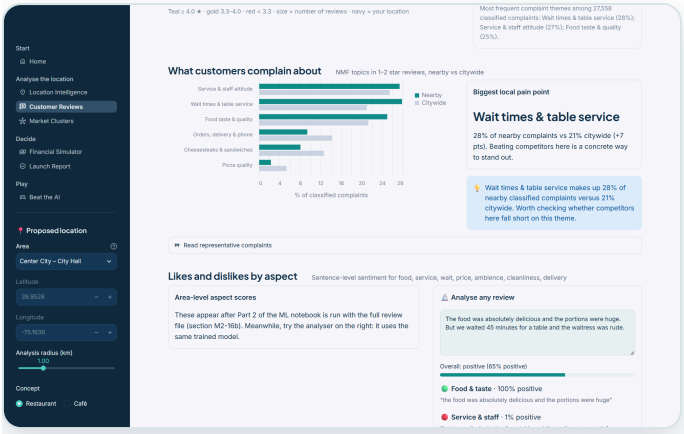
«ماذا لو؟»: تقدير شعبية مطعمك مع النطاق المتوقع 80%.

ذكاء الموقع — سيف

- عدد المطاعم ضمن 0.5 و1 و2 كم مقارنة بالمعتاد في المدينة.
- خريطة المنافسين (الأخضر مفتوح، الرمادي مغلق، والحجم حسب الشعبية) وقائمة بأشهرهم.
- **«ماذا لو؟»:** صِف مطعمك (المطبخ، السعر، الساعات، الخدمات) ليقدّر النموذج عدد المراجعات بعد 1 و2 و3 و5 سنوات مع نطاق ثقة.
- جدول لاستكشاف كل مطاعم المدينة مع بحث وتنزيل CSV.



صفحة آراء العملاء: تقييمات المنافسين وتوزيع المشاعر.

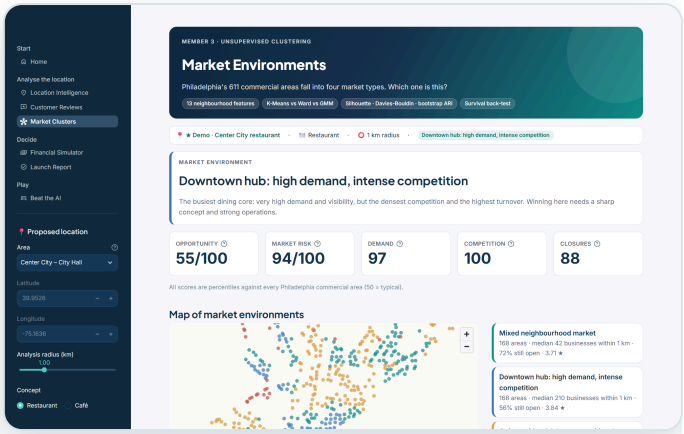


موضوعات الشكاوى محلياً مقابل المدينة، و«أكبر نقطة ألم محلية».

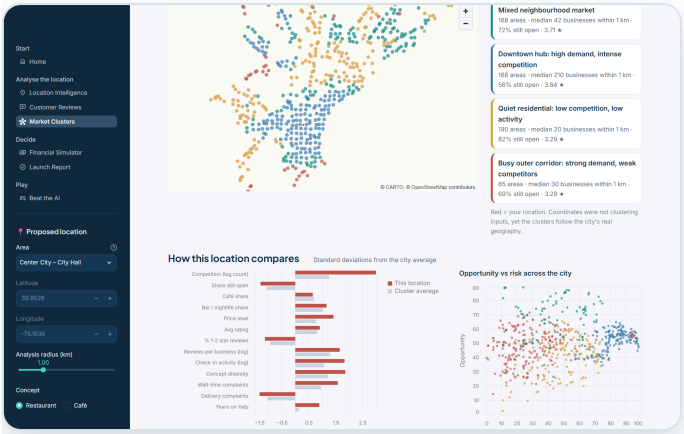
آراء العملاء — مريم

- متوسط تقييم المنافسين ونسبة المراجعات السيئة مقارنة بالمدينة.
- الشكاوى الستة محلياً مقابل المدينة، مع أمثلة حقيقية لكل موضوع.
- **محلل المراجعات المباشر:** الصق أي مراجعة لترى المشاعر العامة وتفصيلها حسب الجوانب.

🗺️ البيئات السوقية و 💰 المحاكي المالي



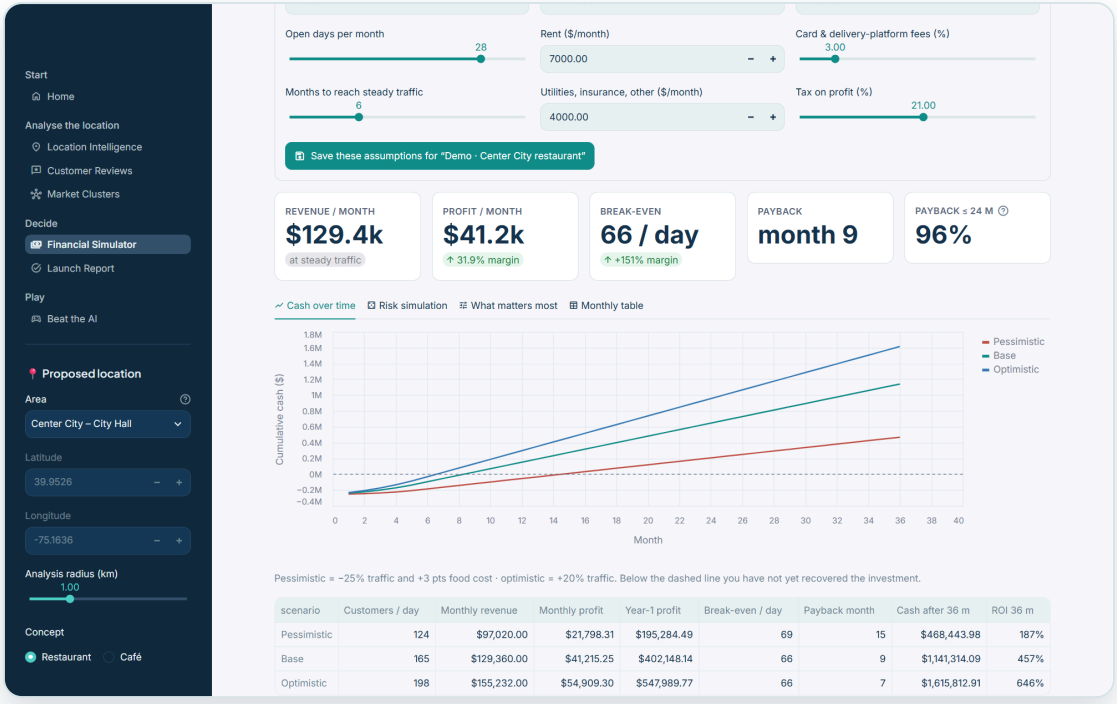
صفحة البيئات السوقية: هوية المنطقة ودرجاتها.



خريطة البيئات الأربع مع بطاقات التعريف.

🗺️ البيئات السوقية بلال

تعرض نوع السوق ووصفه لصاحب المشروع، ودرجات الطلب والمنافسة والإغلاق، ومقارنة خصائص الموقع بمتوسط مجموعته، وموقعه على مخطط «الفرصة مقابل المخاطرة»، ونتيجة اختبار البقاء.

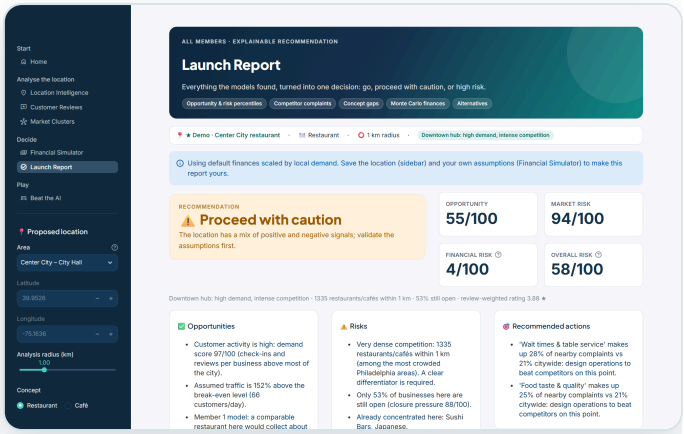


المحاكي المالي: الإيراد والربح ونقطة التعادل وفترة الاسترداد واحتمال الاسترداد خلال 24 شهراً.

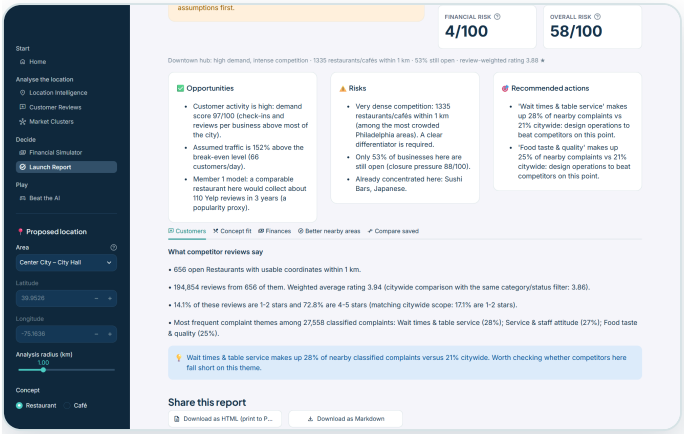
💰 المحاكي المالي بلال

عدّل الإيجار والرواتب وعدد العملاء والفاتورة، فتتحدّث النتائج فوراً: ثلاثة سيناريوهات، و4,000 محاكاة، وأكثر الافتراضات تأثيراً، وجدول شهري. ثم اضغط **«حفظ هذه الافتراضات»** ليستخدمها تقرير الإطلاق.

📋 تقرير الإطلاق



بطاقة الحكم والدرجات الأربع.



الفرص والمخاطر والإجراءات المقترحة.

هذه الصفحة تجمع عمل الأعضاء الثلاثة في قرار واحد:

- **بطاقة الحكم:** واعد ✅ أو تقدّم بحذر ⚠️ أو مخاطرة عالية ⛔ مع سبب واضح.
- **الدرجات:** الفرصة، ومخاطرة السوق، والمخاطرة المالية، والمخاطرة الكلية.
- **ثلاث بطاقات:** الفرص ✅، والمخاطر ⚠️، والإجراءات المقترحة 🎯.
- **تبويبات:** ماذا يقول العملاء، وملاءمة نوع المطبخ، والملخص المالي، ومناطق أفضل قريبة (مع زر «حلّل هذه المنطقة»)، و**مقارنة كل المواقع المحفوظة** جنباً إلى جنب.
- **المشاركة:** تنزيل التقرير بصيغة HTML قابلة للطباعة PDF، أو Markdown.

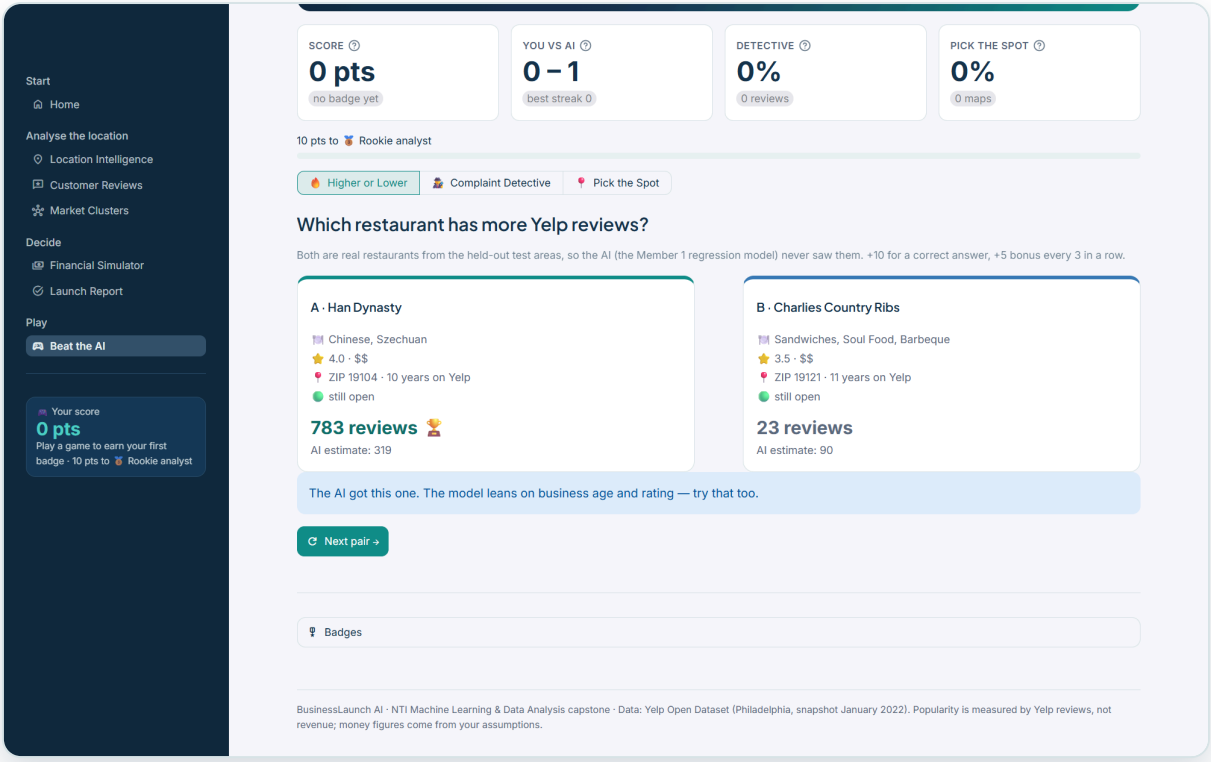
💾 طريقة العمل الموصى بها

1. اختر موقعاً واحفظه من الشريط الجانبي.
2. أدخل أرقامك الحقيقية في المحاكي المالي واحفظها.
3. افتح تقرير الإطلاق: سيستخدم افتراضاتك تلقائياً.
4. كرر لموقعين أو ثلاثة، ثم قارن بينها في تبويب «مقارنة المحفوظ».

الألعاب التفاعلية

🎮 تحدَّ الذكاء الاصطناعي

لجعل الموقع ممتعاً ولشرح ما تعلّمته النماذج، أضفنا ثلاث ألعاب قصيرة تعتمد على بيانات حقيقية والنماذج المدرّبة نفسها، مع نقاط وسلاسل فوز وأربع شارات.



لعبة «أعلى أم أقل»: مطعمان حقيقيان، وبعد الإجابة يظهر العدد الحقيقي وتقدير النموذج.

🔥 أعلى أم أقل

أي المطعمين لديه مراجعات أكثر؟ تنافس نموذج سيف. المطاعم من مناطق الاختبار فقط، أي أن النموذج لم يرها من قبل. +10 نقاط، ومكافأة +5 كل 3 إجابات متتالية.

🕵️ محقق الشكاوى

اقرأ شكوى حقيقية (1-2★) وخمّن موضوعها، وتنافس نموذج موضوعات مريم، ثم شاهد تحليل المشاعر لكل جملة. +10 نقاط.

📍 اختر المكان

أربع مناطق حقيقية على الخريطة: أين ستفتح؟ يرتبها نموذج بلال للمخاطرة الذي اختبرناه على حالات الإغلاق الحقيقية. +15 للأفضل و+5 للثاني.

الشارة	النقاط المطلوبة
🥉 محلل مبتدئ	10
🥈 مستكشف السوق	40
🥇 خبير المواقع	80
🏆 أسطورة BusinessLaunch	150

جودة الكود والنشر

منظّم، ومختبَر، وقابل لإعادة الإنتاج

10	21	8	3 + 1
اختبارات وحدات (المالية، الخصائص، الدرجات، الجوانب)	اختبار عرض: 7 صفحات × 3 مواقع	فحوصات ضد تسريب البيانات	ألعاب ومسار الحفظ تم النقر عليها آلياً

التقنيات المستخدمة

المجال	الأدوات
البيانات والتحليل	Python 3.11 · pandas · NumPy · SciPy
تعلّم الآلة	scikit-learn 1.9.1 (HistGradientBoosting, Logistic Regression, NMF, K-Means…)
الرسوم والخرائط	Matplotlib · Altair · pydeck (CARTO / OpenStreetMap)
التطبيق	Streamlit 1.65 · st.navigation · custom theme (config.toml)
إدارة الكود	Git · GitHub · unit & app tests

تشغيل المشروع على جهازك

```
git clone https://github.com/BelalOsaKa/BusinessLaunchAI.git
cd BusinessLaunchAI
pip install -r requirements.txt
streamlit run app/Home.py
```

في ويندوز يمكن أيضاً النقر مرتين على `run_app.bat` . التطبيق لا يحتاج ملفات البيانات الكبيرة، لأن النماذج المدرّبة محفوظة في مجلد `outputs/` .

النشر على Streamlit Community Cloud

1. ادخل إلى share.streamlit.io بحساب GitHub واختر Create app.
2. المستودع BelalOsaKa/BusinessLaunchAI، الفرع main، الملف الرئيسي app/Home.py.
3. من Advanced settings اختر **Python 3.11** (النماذج حُفظت بهذا الإصدار).
4. اضغط Deploy. أول تشغيل يستغرق بضع دقائق لتثبيت المكتبات.

في النسخة المنشورة تُحفظ المواقع لكل زائر خلال جلسته فقط (لأن الخادم مشترك بين الجميع)، بينما على جهازك تُحفظ في ملف دائم.

الدروس المستفادة

التحديات والحلول

التحدي	الحل
النموذج الأول بالموقع فقط كان ضعيفاً ($R^2 = 0.06$)	هندسة خصائص جديدة: العمر، والخصائص، والساعات، وحركة الجيران ← $R^2 = 0.61$
خطر تسريب البيانات بين الجيران وبين مراجعات المطعم نفسه	تقسيم مكاني بمربعات، وتقسيم المراجعات حسب المطعم، و8 فحوصات آلية
ملف مراجعات 5 GB على حاسوب بذاكرة 8 GB	القراءة على دفعات، والاحتفاظ بالأعمدة اللازمة فقط، وعينة 100 ألف للتدريب
دمج عمل ثلاثة أعضاء بقوائم ومسارات مختلفة	عالم أنشطة واحد مرتبط بـ `business_id`، وحزمة كود مشتركة، ودفتر واحد
لا توجد بيانات إيرادات في Yelp	محاكٍ شفاف مبني على الافتراضات مع مونت كارلو، واختبار درجة المخاطرة على حالات الإغلاق
أسماء موضوعات NMF غير مفهومة	تسميتها بعد قراءة الكلمات الأهم والمراجعات النموذجية

القيود

- عدد المراجعات مقياس للشعبية على Yelp وليس للإيرادات.
- لقطة زمنية واحدة (يناير 2022) دون تواريخ الإغلاق.
- تسميات المشاعر من النجوم لا تلتقط السخرية والمراجعات المختلطة.
- المطاعم الشهيرة جداً ما زالت تُقدَّر بأقل من حقيقتها.
- الأرقام المالية افتراضات المستخدم.
- التحليل داخل حدود مدينة فيلادلفيا فقط.

العمل المستقبلي

- التحقق من الأحكام على مطاعم افتُتحت بعد 2022 (بيانات تراخيص المدينة).
- إضافة بيانات الدخل والإيجارات وحركة المشاة.
- نموذج DistilBERT لتحليل الجوانب (يحتاج GPU).
- خصائص الاتجاه الزمني من المراجعات المؤرخة.
- تشغيل تحسينات NLP الجاهزة على ملف المراجعات الكامل.
- التوسع إلى مدن أخرى.

الخلاصة

السؤال... والإجابة بالأدلة

R^2 0.61 المنافسة والشعبية على مناطق لم يرها النموذج	**F1 0.944** مشاعر العملاء على مطاعم جديدة + 6 موضوعات للشكاوى	**4 · 0.87** بيئات سوقية ثابتة
27→45% نسبة الإغلاق بين المخاطرة المنخفضة والعالية	**4,000** مستقبل محاكى لكل قرار مالي	**7 + 3** صفحات وألعاب، كلها مختبرة

الفكرة الأهم: الازدحام لا يعني الأمان. أفضل الفرص تجمع بين **طلب حقيقي**، و**منافسين ضعفاء**، و**أرقام مالية مجدية**.

مسرد المصطلحات

المصطلحات عربي – إنجليزي

المصطلح بالعربية	بالإنجليزية	المعنى المبسّط
الانحدار	Regression	التنبؤ بقيمة رقمية، مثل عدد المراجعات
التصنيف	Classification	التنبؤ بفئة، مثل إيجابي أو سلبي
التجميع	Clustering	تقسيم البيانات إلى مجموعات متشابهة دون تسميات مسبقة
هندسة الخصائص	Feature engineering	بناء متغيرات جديدة مفيدة من البيانات الخام
تسريب البيانات	Data leakage	تسرب معلومات الاختبار إلى التدريب فتبدو النتائج أفضل من الحقيقة
التحقق المتقاطع	Cross-validation	تقييم النموذج على عدة تقسيمات للبيانات
متوسط الخطأ المطلق	MAE	متوسط الفرق بين التقدير والحقيقة
معامل التحديد	R^2	نسبة التباين التي يفسرها النموذج (1 = مثالي)
مقياس F1 الكلي	Macro F1	متوسط F1 للفئتين، مناسب للبيانات غير المتوازنة
تكرار المصطلح × ندرته	TF-IDF	تحويل النص إلى أرقام مع إبراز الكلمات المميزة
تحليل المصفوفات غير السالبة	NMF	اكتشاف الموضوعات المتكررة في النصوص
معامل الصورة الظلية	Silhouette	مدى انفصال المجموعات عن بعضها
محاكاة مونت كارلو	Monte Carlo	تكرار الحساب آلاف المرات بقيم عشوائية لتقدير الاحتمالات
نقطة التعادل	Break-even	عدد العملاء الذي يجعل الربح صفراً
المئين	Percentile	ترتيب القيمة مقارنة بغيرها من 0 إلى 100